
机器智能复习讲义

Machine Intelligence

2026 年 7 月版

整理与编写: Lingfeng Zhang

课程材料: Yaqing Wang, BIMSA, 2025 秋季

补充讲义: Pang Tongyao, Lecture 7 Unsupervised Learning

资料截止日期: 2026 年 7 月 20 日

编写说明

本讲义将文件夹中的十二份课程 Slide、一份无监督学习补充 Slide，以及 Boyd 等人的 ADMM 专论整合为一套紧凑复习材料。编排遵循“学习问题 → 经典方法 → 优化 → 神经网络架构 → 生成式模型与智能体”的依赖关系，而不是原始文件的页序。

处理原则如下：

1. 保留定义、假设、目标函数、算法步骤、关键推导、典型结构和失败模式；
2. 删除重复封面、Roadmap、致谢、课堂提示和只起装饰作用的图片；
3. 修正明显拼写和术语错误，例如 *Principal Component Analysis*、*Voting*、*Variational Autoencoder*、*AdamW*；
4. 对材料缺失的 MLP、LLM 进阶、Agent 和 Meta-Learning 章节，仅用原始论文或权威标准补齐，并在参考文献中标明；
5. 数学公式以标准定义为准。若 Slide 为直观表达而省略条件，本讲义补上必要条件。

阅读建议

第一次阅读可依次学习第 1–15 章。考前复习可先看附录 B 的算法选型与公式速查，再回到相应章节核对假设、目标函数和复杂度。附录 C 给出逐 PDF 的覆盖映射。

统一记号

记号	含义
$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$	有监督数据集；无监督场景只保留 $\{x_i\}_{i=1}^n$ 。
$x_i \in \mathbb{R}^d$	第 i 个输入； $X \in \mathbb{R}^{n \times d}$ 的第 i 行为 $x_i^\top$ 。
f_θ	参数为 θ 的模型； $\hat{y}_i = f_\theta(x_i)$ 。
$\ell(\hat{y}, y)$	单样本损失； $\mathcal{L}(\theta)$ 表示经验目标或总体目标。
p_θ	参数化概率分布； $\mathbb{E}$ 、 Var 、 Cov 分别表示期望、方差、协方差。
$G = (V, E)$	图； V 是节点集合， E 是边集合。
Q, K, V	注意力中的查询、键和值矩阵；与图的节点集合 V 由上下文区分。
$\ x\ _p$	向量 p -范数；未写下标时默认为二范数。

目录

编写说明	i
统一记号	ii
第一部分 机器学习基础	1
第一章 机器智能与学习范式	2
1.1 从任务到学习问题	2
1.2 主要学习范式	2
1.3 数据划分与评价	3
1.4 拟合、泛化与归纳偏置	3
1.5 历史线索	3
第二章 分类：从邻域到最大间隔	4
2.1 k 近邻	4
2.2 支持向量机	4
2.3 决策树	5
2.4 分类器选择	6
第三章 回归、概率分类与正则化	7
3.1 线性回归	7
3.2 逻辑回归	7
3.3 Ridge 与 Lasso	8
3.4 泛化误差与模型选择	8
第四章 集成学习	9
4.1 投票与平均	9
4.2 Bagging 与随机森林	9
4.3 Boosting	9
4.3.1 AdaBoost	9

4.3.2 梯度提升	10
4.4 Stacking 与数据泄漏	10
第五章 无监督学习与自监督表征	11
5.1 聚类	11
5.1.1 K-means	11
5.1.2 DBSCAN 与谱聚类	11
5.2 密度估计	12
5.2.1 高斯混合模型	12
5.2.2 核密度估计	12
5.3 降维	12
5.3.1 主成分分析	12
5.4 自监督与对比学习	13
5.5 去噪、先验与自编码器	13
第六章 优化：从梯度下降到近端方法	14
6.1 问题、光滑性与收敛	14
6.2 动量与 Nesterov 加速	14
6.3 随机梯度与学习率	14
6.4 AdaGrad、RMSProp、Adam 与 AdamW	15
6.5 近端梯度、ISTA 与 FISTA	15
6.6 训练诊断	16
第七章 多层感知机与反向传播	17
7.1 从感知机到深层网络	17
7.2 反向传播	17
7.3 初始化、归一化与正则化	18
第二部分 神经网络架构	19
第八章 卷积神经网络与架构搜索	20
8.1 局部性、共享与等变性	20
8.2 卷积模块	20
8.3 经典架构	21
8.4 神经架构搜索	21

第九章 图表示学习与图神经网络	22
9.1 图数据与任务	22
9.2 图嵌入	22
9.3 消息传递	22
9.4 Graph Transformer 与基础模型	23
9.5 理论：表达、训练与泛化	23
9.5.1 表达力与 WL 检验	23
9.5.2 过平滑与过挤压	23
第十章 序列、注意力与 Transformer	25
10.1 RNN 与 Seq2Seq	25
10.2 编码器-解码器注意力	25
10.3 缩放点积注意力	25
10.4 Transformer 架构	26
10.5 复杂度与稀疏注意力	26
10.6 代表性应用	26
第三部分 生成式模型与基础模型	28
第十一章 生成模型：自回归、VAE、GAN 与扩散	29
11.1 分布建模与分类	29
11.2 自回归模型	29
11.3 自编码器与变分自编码器	30
11.4 生成对抗网络	30
11.5 扩散模型	31
11.6 四类模型的权衡	31
第十二章 大语言模型基础与训练	32
12.1 Tokenization 与表示	32
12.2 预训练目标与架构	32
12.3 监督微调与指令微调	32
12.4 RLHF 与偏好建模	33
12.5 DPO	33
12.6 上下文学习	33

12.7 LoRA 参数高效微调	34
第十三章 LLM 进阶：推理、检索与风险	35
13.1 Chain-of-Thought	35
13.2 检索增强生成	35
13.3 能力边界与评价	36
13.4 生成式 AI 风险	36
第十四章 LLM Agent：规划、记忆与工具	37
14.1 Agent 的形式化视角	37
14.2 ReAct	37
14.3 规划与搜索	38
14.4 工具使用	38
14.5 记忆	38
14.6 评测与安全	38
第十五章 元学习与少样本适应	39
15.1 任务分布与 episodic training	39
15.2 度量式元学习	39
15.3 MAML	40
15.4 与迁移学习和 ICL 的关系	40
附录 A ADMM 与分布式优化	41
A.1 从对偶上升到增广拉格朗日	41
A.2 标准 ADMM	41
A.3 残差与停止准则	42
A.4 近端形式与常见模式	42
A.5 Lasso 示例	42
A.6 共识与共享	43
A.7 变体与实践	43
附录 B 总复习：算法选型与公式速查	44
B.1 按问题结构选方法	44
B.2 优化器速查	44
B.3 核心公式索引	45
B.4 考前自检	45

附录 C PDF 来源与章节覆盖	46
中英术语表	47
参考文献	47

第一部分

机器学习基础

第一章 机器智能与学习范式

本章导读

机器学习把任务、数据、模型、损失和优化器连成一个可检验的系统。本章建立全书共同语言，并说明训练误差为何不能替代泛化能力。

1.1 从任务到学习问题

定义 1.1: 机器学习

给定任务分布、数据和评价准则，机器学习（machine learning）通过经验自动改进模型 f_θ 的性能。一个完整问题至少包含输入输出、假设空间、损失、数据分布和评价协议。

有监督学习的经验风险最小化（empirical risk minimization, ERM）写作

$$\hat{\theta} = \arg \min_{\theta \in \Theta} \hat{R}_n(\theta), \quad \hat{R}_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(f_\theta(x_i), y_i). \quad (1.1)$$

真正关心的是总体风险

$$R(\theta) = \mathbb{E}_{(x,y) \sim p_{\text{data}}} [\ell(f_\theta(x), y)], \quad (1.2)$$

而训练集只能给出它的有限样本估计。模型、优化和数据三者分别决定表达能力、能否找到好参数、以及经验风险能否代表未来样本。




图 1.1: 一个可复现的机器学习闭环。

1.2 主要学习范式

有监督学习（supervised learning） 输入和标签成对出现。分类预测离散标签，回归预测连续量。
无监督学习（unsupervised learning） 只有输入，目标是发现聚类、低维结构、密度或可迁移表示。

自监督学习（self-supervised learning） 从数据本身构造监督信号，如遮盖预测、对比学习和下一词预测。

强化学习 (reinforcement learning) 智能体通过状态、动作和奖励与环境交互，学习最大化长期回报的策略。

元学习 (meta-learning) 在任务分布上学习，使模型面对新任务时能用少量样本快速适应。

生成式模型与判别式模型关注不同分布：

判别式： $p_{\theta}(y|x)$ ， 生成式： $p_{\theta}(x)$ 或 $p_{\theta}(x, y)$ 。

现代基础模型常同时经历自监督预训练、有监督指令微调和偏好优化，不能简单归入单一范式。

1.3 数据划分与评价

训练集用于拟合参数，验证集用于模型选择和超参数调整，测试集只用于最终估计。任何依据测试集反复调整模型的行为都会产生测试泄漏。分类常用准确率、精确率、召回率、F1、ROC-AUC；回归常用均方误差、平均绝对误差和决定系数 R^2 。类别极不均衡时，准确率可能误导。

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R}. \quad (1.3)$$

1.4 拟合、泛化与归纳偏置

平方损失下，期望预测误差可概念性分解为

$$\mathbb{E}[(y - \hat{f}(x))^2] = \text{Bias}^2[\hat{f}(x)] + \text{Var}[\hat{f}(x)] + \sigma^2. \quad (1.4)$$

简单模型可能高偏差，过度灵活的模型可能高方差。正则化、数据增强、早停和交叉验证都是控制泛化误差的方法。所谓归纳偏置 (inductive bias) 是模型在有限数据之外作出推断所依赖的结构假设，例如 CNN 的局部性和平移等变性、GNN 的置换等变性。

易错点

训练损失低不等于模型好；参数更多也不必然导致测试误差更高。应同时报告数据划分、模型选择过程和独立测试结果。

1.5 历史线索

机器智能经历符号主义、早期神经网络、专家系统、统计学习与深度学习等阶段。算力、数据、可微模型和优化方法共同促成了现代复兴。历史的实际启示是：能力来自算法、数据、硬件和评价体系的共同作用，单一因素不足以解释模型进步。

第二章 分类：从邻域到最大间隔

本章导读

本章比较三类互补归纳偏置：k-NN 依赖局部相似性，SVM 追求最大间隔，决策树递归划分特征空间。重点是目标函数、核技巧、树的分裂准则与复杂度。

2.1 k 近邻

k 近邻 (k-nearest neighbors, k-NN) 不显式拟合参数。给定距离 d 和邻居集合 $\mathcal{N}_k(x)$ ，分类器为

$$\hat{y}(x) = \arg \max_c \sum_{i \in \mathcal{N}_k(x)} w_i \mathbf{1}(y_i = c), \quad w_i = 1 \text{ 或 } \frac{1}{d(x, x_i) + \epsilon}. \quad (2.1)$$

回归时改为邻居目标值的加权平均。较小的 k 方差高，较大的 k 偏差高；通常通过验证集选择。

算法：k-NN 分类

1. 用训练集统计量标准化连续特征，并选定距离度量。
2. 计算查询点与所有训练样本的距离，取最近的 k 个样本。
3. 对邻居标签作多数投票或距离加权投票。
4. 若票数相同，使用固定且可复现的规则打破平局。

朴素查询时间为 $O(nd)$ ，存储为 $O(nd)$ 。低维空间可用 k-d tree 或 ball tree；高维时距离集中，树索引也会退化，这就是维数灾难 (curse of dimensionality) 的一种表现。

2.2 支持向量机

对二分类 $y_i \in \{-1, +1\}$ ，线性分类面为 $w^T x + b = 0$ 。硬间隔 SVM 在完全可分时最大化几何间隔；软间隔支持向量机 (support vector machine, SVM) 的原问题为

$$\begin{aligned} \min_{w, b, \xi} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & y_i (w^T \phi(x_i) + b) \geq 1 - \xi_i, \quad \xi_i \geq 0. \end{aligned} \quad (2.2)$$

它等价于带 hinge loss 的正则化经验风险。 C 大时更重视训练误差， C 小时更重视大间隔。

定理 2.1: 软间隔 SVM 的对偶

在满足凸优化的标准正则条件时，式 (2.2) 的对偶为

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq C, \quad \sum_{i=1}^n \alpha_i y_i = 0, \end{aligned} \quad (2.3)$$

其中 $K(x_i, x_j) = \phi(x_i)^\top \phi(x_j)$ 。预测只依赖 $\alpha_i > 0$ 的支持向量：

$$\hat{y}(x) = \text{sign} \left(\sum_i \alpha_i y_i K(x_i, x) + b \right).$$

常见核包括多项式核和径向基核

$$K_{\text{RBF}}(x, z) = \exp(-\gamma \|x - z\|^2).$$

核必须对应某个内积；任意相似度函数不一定是合法核。多分类可用 one-vs-rest 或 one-vs-one，不能把二分类对偶公式直接当作多分类模型。

易错点

SVM 的间隔是 $2/\|w\|$ ，但这依赖规范化约束 $y_i(w^\top x_i + b) \geq 1$ 。若任意缩放 w, b 而不固定函数间隔，谈几何间隔没有意义。

2.3 决策树

决策树通过递归分裂得到分段常数预测。分类节点常用熵或 Gini 不纯度：

$$H(S) = - \sum_{c=1}^C p_c \log p_c, \quad (2.4)$$

$$G(S) = 1 - \sum_{c=1}^C p_c^2. \quad (2.5)$$

候选分裂 $S \rightarrow \{S_m\}$ 的信息增益为

$$\text{Gain} = I(S) - \sum_m \frac{|S_m|}{|S|} I(S_m). \quad (2.6)$$

ID3 主要用信息增益；C4.5 用增益率以减轻多值特征偏好；CART 使用二叉分裂，分类常用 Gini，回归常用平方误差。

算法：递归建树

1. 在当前节点枚举特征及阈值，选取不纯度下降最大的合法分裂。
2. 将数据送入子节点并递归重复。
3. 达到最大深度、最小样本数或最小增益时停止。

4. 用预剪枝或基于验证误差的代价复杂度剪枝控制过拟合。

树无需标准化，能表达非线性交互并容易解释，但单棵深树不稳定。随机森林和提升树通过集成降低这一缺点，见章 四。

2.4 分类器选择

表 2.1: 三类分类器的主要权衡。

方法	优点	局限	关键超参数
k-NN	无训练过程, 局部边界灵活	查询慢、尺度敏感、高维退化	k 、距离、权重
SVM	最大间隔、核方法适合中小数据	大样本核矩阵昂贵, 概率解释需校准	C 、核、 γ
决策树	可解释、无需缩放、处理交互	高方差、轴对齐分裂可能低效	深度、叶节点样本数

第三章 回归、概率分类与正则化

本章导读

线性回归展示闭式解与最小二乘，逻辑回归展示概率分类。Ridge、Lasso 和早停说明如何以偏差换方差，并把模型选择纳入泛化分析。

3.1 线性回归

加入截距后的线性模型写作 $\hat{y} = Xw$ 。平方损失为

$$\mathcal{L}(w) = \frac{1}{2n} \|Xw - y\|^2. \quad (3.1)$$

若 $X^T X$ 可逆，正规方程给出

$$\hat{w} = (X^T X)^{-1} X^T y. \quad (3.2)$$

更稳健的实现使用 QR、SVD 或伪逆，而不是显式计算逆矩阵。梯度为 $\nabla \mathcal{L}(w) = X^T (Xw - y)/n$ ，因此也可用梯度下降处理大数据。

命题 3.1: 最小二乘的几何意义

最小二乘残差 $r = y - X\hat{w}$ 与 X 的列空间正交，即 $X^T r = 0$ 。因此 $X\hat{w}$ 是 y 在列空间上的正交投影。

3.2 逻辑回归

尽管名称含“回归”，逻辑回归（logistic regression）通常用于分类。二分类模型为

$$p_{\theta}(y = 1 | x) = \sigma(w^T x + b), \quad \sigma(z) = \frac{1}{1 + e^{-z}}. \quad (3.3)$$

负对数似然即二元交叉熵：

$$\mathcal{L}(w, b) = -\frac{1}{n} \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)]. \quad (3.4)$$

多分类使用 softmax：

$$p(y = c | x) = \frac{\exp(z_c)}{\sum_{j=1}^C \exp(z_j)}.$$

实际计算应使用 log-sum-exp 技巧，避免直接指数运算溢出。

3.3 Ridge 与 Lasso

Ridge 回归加入二范数惩罚：

$$\hat{w}_{\text{ridge}} = \arg \min_w \frac{1}{2n} \|Xw - y\|^2 + \frac{\lambda}{2} \|w\|^2. \tag{3.5}$$

在一致的缩放约定下，其闭式解为

$$\hat{w}_{\text{ridge}} = (X^T X + n\lambda I)^{-1} X^T y.$$

若损失未除以 n ，对应矩阵中的系数是 λ 而非 $n\lambda$ ；两种写法都可以，但不能混用。截距通常不惩罚。

Lasso 使用一范数：

$$\hat{w}_{\text{lasso}} = \arg \min_w \frac{1}{2n} \|Xw - y\|^2 + \lambda \|w\|_1. \tag{3.6}$$

一范数在零点不可微，却能产生精确的稀疏解。它可通过坐标下降、近端梯度或 ADMM 求解。

表 3.1: Ridge 与 Lasso 的比较。

性质	Ridge	Lasso
惩罚	$\lambda \ w\ _2^2/2$	$\lambda \ w\ _1$
典型效果	连续收缩、保留相关特征组	稀疏化、进行变量选择
闭式解	线性回归时存在	一般不存在
相关特征	倾向共同保留	可能任意选择其中一项

3.4 泛化误差与模型选择

正则强度、特征处理和模型结构必须只根据训练集与验证集选择。 K 折交叉验证将数据轮流分为训练折和验证折，可降低单次划分的偶然性。若还需报告无偏性能，应保留独立测试集；嵌套交叉验证把超参数选择放在内层。

易错点

标准化必须用训练集统计量拟合，再应用到验证集和测试集。先在全数据上标准化会泄漏信息。对于 Lasso，尺度还直接改变惩罚的相对强度。

第四章 集成学习

本章导读

集成学习 (ensemble learning) 通过组合多个模型降低方差、降低偏差或提高稳健性。核心区别在于基学习器是并行独立训练、串行纠错，还是由元学习器再组合。

4.1 投票与平均

硬投票选择多数类别；软投票平均经过校准的类别概率：

$$\hat{y}_{\text{hard}} = \text{mode}\{\hat{y}_m\}_{m=1}^M, \quad \hat{y}_{\text{soft}} = \arg \max_c \sum_{m=1}^M a_m p_m(y = c | x).$$

回归通常作加权平均。有效集成要求基模型既有能力又有差异；高度相关的错误难以通过平均消除。

4.2 Bagging 与随机森林

Bagging 对训练集作有放回的 bootstrap 抽样，并行训练 M 个模型后平均。若单模型方差为 σ^2 ，两两相关系数近似为 ρ ，平均后的方差为

$$\rho\sigma^2 + \frac{1-\rho}{M}\sigma^2. \quad (4.1)$$

增加模型数只能消除第二项，因此随机森林还在每个节点随机抽取候选特征以降低相关性。未被某次 bootstrap 抽中的样本可作袋外 (out-of-bag, OOB) 估计。

4.3 Boosting

4.3.1 AdaBoost

二分类 AdaBoost 维护样本权重 $w_i^{(t)}$ 。第 t 个弱分类器的加权错误率与权重为

$$\epsilon_t = \frac{\sum_i w_i^{(t)} \mathbf{1}(h_t(x_i) \neq y_i)}{\sum_i w_i^{(t)}}, \quad \alpha_t = \frac{1}{2} \log \frac{1 - \epsilon_t}{\epsilon_t}. \quad (4.2)$$

随后更新

$$w_i^{(t+1)} \propto w_i^{(t)} \exp[-\alpha_t y_i h_t(x_i)], \quad (4.3)$$

最终分类器为 $\text{sign}(\sum_t \alpha_t h_t(x))$ 。错误样本被放大，但标签噪声也可能被过度强调。

4.3.2 梯度提升

梯度提升把加法模型 $F_t = F_{t-1} + \eta h_t$ 看作函数空间中的梯度下降。伪残差为

$$r_{it} = - \left. \frac{\partial \ell(y_i, F(x_i))}{\partial F(x_i)} \right|_{F=F_{t-1}},$$

新弱学习器拟合这些负梯度。学习率、小树深度、树数和子采样共同控制偏差与方差。

4.4 Stacking 与数据泄漏

Stacking 用元学习器组合异构基模型。训练元学习器时必须使用基模型的折外预测：若直接使用基模型在其训练数据上的预测，元学习器会看到过度乐观的特征并产生泄漏。

表 4.1: 主要集成策略。

策略	训练关系	主要目的	代表方法
Voting	独立	综合不同观点	硬投票、软投票
Bagging	并行	降低方差	Random Forest
Boosting	串行	逐步降低偏差	AdaBoost、Gradient Boosting
Stacking	分层	学习如何组合	折外预测加元学习器

第五章 无监督学习与自监督表征

本章导读

无监督学习从无标签数据中寻找分组、低维结构或概率密度；自监督学习则从输入本身构造预测任务。本章合并两套讲义中的经典方法、对比学习、遮盖学习、去噪先验和自编码器。

5.1 聚类

5.1.1 K-means

K-means 以质心表示簇，优化

$$\min_{\{c_i\}, \{\mu_k\}} \sum_{i=1}^n \sum_{k=1}^K c_{ik} \|x_i - \mu_k\|^2, \quad c_{ik} \in \{0, 1\}, \quad \sum_{k=1}^K c_{ik} = 1. \quad (5.1)$$

算法：K-means 交替最小化

1. 初始化 K 个质心，优先使用 K-means++ 降低坏初始化概率。
2. 分配： $c_{ik} = 1$ 当且仅当 k 是距离 x_i 最近的质心。
3. 更新： $\mu_k = \sum_i c_{ik} x_i / \sum_i c_{ik}$ 。
4. 重复分配与更新，直到目标下降小于阈值或达到迭代上限。

每步都不增加目标，但算法只保证收敛到局部最优。它偏好近似球形、尺度相近的簇，对异常点和特征尺度敏感。

5.1.2 DBSCAN 与谱聚类

DBSCAN 用邻域半径 ε 和最小邻居数 $minPts$ 定义核心点，由密度可达关系扩展簇。它能发现非凸形状并标记噪声，但不同密度并存时难以选统一 ε 。

谱聚类先构造相似度图 W ，令 $D_{ii} = \sum_j W_{ij}$ 。常见归一化 Laplacian 为

$$L_{\text{sym}} = I - D^{-1/2} W D^{-1/2}.$$

取最小特征值对应的若干特征向量作为嵌入，再运行 K-means。它把非凸结构转化为谱空间中的可分结构，代价是构图和特征分解可能达到 $O(n^2)$ 存储与 $O(n^3)$ 时间。

5.2 密度估计

5.2.1 高斯混合模型

高斯混合模型 (Gaussian mixture model, GMM) 假设

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k), \quad \pi_k \geq 0, \quad \sum_k \pi_k = 1. \quad (5.2)$$

EM 算法的 E 步计算责任度

$$\gamma_{ik} = \frac{\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(x_i | \mu_j, \Sigma_j)},$$

M 步用责任度加权更新 π_k, μ_k, Σ_k 。与 K-means 的硬分配相比, GMM 给出软分配并能表达椭圆簇; 协方差退化时需正则化。

5.2.2 核密度估计

核密度估计 (kernel density estimation, KDE) 为

$$\hat{p}_h(x) = \frac{1}{nh^d} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right). \quad (5.3)$$

带宽 h 过小会得到尖锐且高方差的密度, 过大则过度平滑。KDE 在高维同样受维数灾难影响。

5.3 降维

5.3.1 主成分分析

中心化数据矩阵为 X_c , 样本协方差 $S = X_c^T X_c / (n - 1)$ 。第一主成分满足

$$v_1 = \arg \max_{\|v\|=1} v^T S v, \quad (5.4)$$

因此是 S 最大特征值的特征向量。取前 r 个正交特征向量组成 V_r , 投影与重构为

$$Z = X_c V_r, \quad \hat{X} = Z V_r^T + \bar{x}.$$

定理 5.1: PCA 的两种最优性

前 r 个主成分同时最大化投影方差, 并在所有秩不超过 r 的线性重构中最小化平方重构误差。数值实现通常直接对 X_c 作截断 SVD, 而不显式形成协方差矩阵。

局部线性嵌入 (locally linear embedding, LLE) 先用邻居线性重构每个样本, 再在低维保持这些权重。t-SNE 将高维和低维邻域转成概率分布并最小化 KL 散度, 适合可视化局部结构, 但二维簇间距离、面积和密度不能直接作定量解释。

5.4 自监督与对比学习

对比学习 (contrastive learning) 让同一样本的两个增强视图接近, 让不同样本远离。SimCLR 的 NT-Xent/InfoNCE 损失可写为

$$\ell_{i,j} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\text{sim}(z_i, z_k)/\tau)}, \quad (5.5)$$

其中 sim 通常是归一化向量的余弦相似度, τ 为温度。SimCLR 依赖大批量产生负样本; MoCo 用动量编码器和队列维护规模更大且变化平滑的负样本库。




图 5.1: 对比学习的正样本对。其他样本通常构成负样本。

遮盖学习 (masked modeling) 隐藏输入的一部分并预测缺失内容。掩码语言模型预测被遮盖 token, 图像掩码自编码器重建图像块; 任务迫使模型利用上下文而不是直接复制输入。

5.5 去噪、先验与自编码器

若观测 $y = x + n$, 去噪模型学习 $f_\theta(y) \approx x$ 。Noise2Noise 在两份独立噪声观测 $y = x + n, y' = x + n'$ 之间训练; 当噪声条件期望为零时, 平方损失的最优预测仍指向干净信号。Noise2Void/Noise2Self 使用邻域预测被遮盖中心, 避免模型学习恒等映射。Deep Image Prior 利用未训练卷积网络的结构偏置拟合单幅图像; 早停防止其最终把噪声也拟合进去。

自编码器 (autoencoder, AE) 由编码器 $z = f_\phi(x)$ 与解码器 $\hat{x} = g_\theta(z)$ 组成, 最小化重构损失。瓶颈、稀疏约束或去噪任务防止平凡复制。线性自编码器在适当条件下学习与 PCA 相同的主子空间, 但基向量不必等同于 PCA 特征向量。

字典学习寻找字典 D 与稀疏编码 α_i :

$$\min_{D, \{\alpha_i\}} \sum_i \frac{1}{2} \|x_i - D\alpha_i\|^2 + \lambda \|\alpha_i\|_1, \quad \|d_k\| \leq 1. \quad (5.6)$$

它可看作具有线性解码器和稀疏潜变量的表征学习。LoRA 也是低秩思想, 但属于参数高效微调, 统一放在章十二。

第六章 优化：从梯度下降到近端方法

本章导读

本章把神经网络训练视为大规模随机非凸优化，并从确定性梯度下降出发，依次讨论动量、SGD、自适应方法和复合目标的近端梯度。

6.1 问题、光滑性与收敛

无约束可微优化写作 $\min_{x \in \mathbb{R}^d} f(x)$ 。若

$$\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|,$$

则称梯度是 L -Lipschitz 的。凸函数满足 $f(y) \geq f(x) + \nabla f(x)^\top (y - x)$ ； μ -强凸还多出 $\mu\|y - x\|^2/2$ 。

梯度下降更新

$$x_{t+1} = x_t - \eta \nabla f(x_t). \quad (6.1)$$

对 L -光滑凸函数，合适固定步长给出函数值误差 $O(1/t)$ ；强凸时可线性收敛。神经网络通常非凸，此时更现实的目标是找到小梯度点并验证其泛化。

6.2 动量与 Nesterov 加速

经典动量为

$$v_t = \beta v_{t-1} + \nabla f(x_{t-1}), \quad (6.2)$$

$$x_t = x_{t-1} - \eta v_t. \quad (6.3)$$

它累积方向一致的梯度并抑制狭长谷底中的振荡。Nesterov 方法在前瞻点计算梯度：

$$v_t = \beta v_{t-1} + \nabla f(x_{t-1} - \eta \beta v_{t-1}), \quad x_t = x_{t-1} - \eta v_t.$$

不同库对 v 与学习率的放置略有不同，比较公式时应先统一变量定义。

6.3 随机梯度与学习率

经验风险的 mini-batch 梯度

$$g_t = \frac{1}{|B_t|} \sum_{i \in B_t} \nabla_{\theta} \ell_i(\theta_t)$$

在均匀采样下是全梯度的无偏估计。SGD 更新 $\theta_{t+1} = \theta_t - \eta_t g_t$ 。较大批量降低方差并提高硬件吞吐，但可能需要学习率热身、缩放和更强正则。

常见调度包括分段衰减、余弦衰减和逆平方根衰减。理论上的 Robbins–Monro 条件

$$\sum_t \eta_t = \infty, \quad \sum_t \eta_t^2 < \infty$$

保证步长足以探索又最终减小，但现代有限轮次训练通常依据验证集选择实用调度。

6.4 AdaGrad、RMSProp、Adam 与 AdamW

AdaGrad 累积逐坐标平方梯度：

$$s_t = s_{t-1} + g_t \odot g_t, \quad \theta_t = \theta_{t-1} - \eta \frac{g_t}{\sqrt{s_t} + \epsilon}.$$

稀疏特征可受益，但单调增长的 s_t 可能使后期步长过小。RMSProp 用指数滑动平均替代累积和：

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2.$$

Adam 同时估计一阶、二阶矩并作偏差修正：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad (6.4)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad (6.5)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}. \quad (6.6)$$

AdamW 将权重衰减与自适应梯度解耦：

$$\theta_t = (1 - \eta_t \lambda) \theta_{t-1} - \eta_t \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}. \quad (6.7)$$

易错点

对 Adam 直接把 $\lambda\theta$ 加进梯度，并不等价于 AdamW 的解耦权重衰减，因为自适应预条件器会同时缩放正则项。

6.5 近端梯度、ISTA 与 FISTA

考虑复合目标

$$\min_x F(x) = f(x) + g(x), \quad (6.8)$$

其中 f 光滑， g 可非光滑但近端算子易算：

$$\text{prox}_{\eta g}(v) = \arg \min_x \left\{ g(x) + \frac{1}{2\eta} \|x - v\|^2 \right\}. \quad (6.9)$$

近端梯度更新为

$$x_{t+1} = \text{prox}_{\eta g}(x_t - \eta \nabla f(x_t)). \quad (6.10)$$

当 $g(x) = \lambda \|x\|_1$ 时，近端算子是逐坐标软阈值

$$[S_{\eta\lambda}(v)]_j = \text{sign}(v_j) \max(|v_j| - \eta\lambda, 0).$$

算法：FISTA

初始化 $x_0 = y_0$ 、 $t_0 = 1$ ，随后重复

$$\begin{aligned}x_{k+1} &= \text{prox}_{\eta g}(y_k - \eta \nabla f(y_k)), \\t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \\y_{k+1} &= x_{k+1} + \frac{t_k - 1}{t_{k+1}}(x_{k+1} - x_k).\end{aligned}$$

对标准凸条件，ISTA 的目标误差为 $O(1/k)$ ，FISTA 提升为 $O(1/k^2)$ 。

6.6 训练诊断

训练损失发散通常先检查学习率、数据尺度、数值溢出和梯度范数；训练停滞再检查初始化、激活饱和、批归一化统计和优化器状态。优化损失低而验证性能差属于泛化问题，不应仅靠换优化器解决。

第七章 多层感知机与反向传播

本章导读

本章补齐课程文件中缺失的 MLP。多层感知机（multilayer perceptron, MLP）通过仿射变换与非线性激活交替组合；反向传播高效计算链式法则所需的向量雅可比积。

7.1 从感知机到深层网络

单个神经元计算

$$a = w^T x + b, \quad h = \phi(a).$$

若只有线性层，即使堆叠多层仍等价于一次线性变换；非线性激活是表达复杂决策边界的关键。常用激活包括

$$\text{ReLU}(a) = \max(0, a), \quad \tanh(a), \quad \sigma(a) = \frac{1}{1 + e^{-a}}.$$

ReLU 计算简单且缓解正区间梯度饱和，但可能出现长期输出为零的“死亡”单元。

具有 L 层的 MLP 前向传播为

$$a^{(\ell)} = W^{(\ell)} h^{(\ell-1)} + b^{(\ell)}, \quad (7.1)$$

$$h^{(\ell)} = \phi_\ell(a^{(\ell)}), \quad h^{(0)} = x. \quad (7.2)$$

分类末层常接 softmax 与交叉熵，回归末层通常保持线性。




图 7.1: MLP 的前向计算与反向梯度传播。

7.2 反向传播

反向传播（backpropagation）不是一种优化器，而是计算梯度的算法 [4]。令 $\delta^{(\ell)} = \partial \mathcal{L} / \partial a^{(\ell)}$ ，则

$$\delta^{(L)} = \frac{\partial \mathcal{L}}{\partial h^{(L)}} \odot \phi'_L(a^{(L)}), \quad (7.3)$$

$$\delta^{(\ell)} = (W^{(\ell+1)})^T \delta^{(\ell+1)} \odot \phi'_\ell(a^{(\ell)}), \quad (7.4)$$

$$\frac{\partial \mathcal{L}}{\partial W^{(\ell)}} = \delta^{(\ell)} (h^{(\ell-1)})^T, \quad \frac{\partial \mathcal{L}}{\partial b^{(\ell)}} = \delta^{(\ell)}. \quad (7.5)$$

其效率来自复用中间结果；反向一次的复杂度与前向传播同阶。

例 7.1: softmax 与交叉熵的简化梯度

若 $p = \text{softmax}(z)$ ，单样本交叉熵为 $\ell = -\sum_c y_c \log p_c$ ，且 y 为 one-hot 标签，则

$$\frac{\partial \ell}{\partial z} = p - y.$$

这不是忽略 softmax 的导数，而是 softmax Jacobian 与交叉熵导数组合后的简化结果。

7.3 初始化、归一化与正则化

初始化 Xavier 初始化适合近似对称激活，He 初始化适合 ReLU；目标是让各层激活与梯度方差不过快放大或衰减。

归一化 Batch Normalization 使用 mini-batch 统计量，训练与推理行为不同；Layer Normalization 在单样本特征维上归一化，更适合序列模型。

Dropout 训练时以概率丢弃单元，并采用 inverted dropout 保持期望尺度；推理时关闭随机掩码。

权重衰减与早停 前者限制参数规模，后者用验证指标限制有效训练时间。

深层网络还面临梯度消失、梯度爆炸和鞍点。残差连接、合适初始化、归一化和梯度裁剪分别从信息通路、尺度与数值稳定性上缓解问题。

表达能力与可学习性

通用逼近结论说明足够宽的网络能逼近广泛函数类，但不保证所需宽度合理、数据足够，也不保证梯度方法能找到该表示。表达能力、优化能力和泛化能力必须分开讨论。

第二部分

神经网络架构

第八章 卷积神经网络与架构搜索

本章导读

卷积神经网络 (convolutional neural network, CNN) 以局部连接和权重共享利用网格结构。本章覆盖卷积尺寸、经典架构、残差连接，以及从手工设计到 NAS 和复合缩放的演进。

8.1 局部性、共享与等变性

深度学习库中的“卷积”通常实际执行互相关 (cross-correlation)。一维多通道形式为

$$Y_{o,i} = b_o + \sum_{c=1}^{C_{in}} \sum_{u=0}^{k-1} W_{o,c,u} X_{c,i+u}. \quad (8.1)$$

数学卷积会翻转核；但核是学习得到的，两种定义的表达能力相同，关键是实现约定一致。

对输入尺寸 n 、核尺寸 k 、padding p 、stride s 和 dilation d ，输出长度为

$$n_{out} = \left\lfloor \frac{n + 2p - d(k-1) - 1}{s} + 1 \right\rfloor. \quad (8.2)$$

二维情形分别对高和宽应用该式。参数量为 $C_{out}(C_{in}k_hk_w + 1)$ ，与空间尺寸无关。

定义 8.1: 平移等变性

若算子 F 对平移 T_Δ 满足 $F(T_\Delta x) = T_\Delta F(x)$ ，则称其平移等变。无边界效应、stride 为 1 的卷积近似满足该性质。分类模型通过池化或全局汇聚进一步获得近似的平移不变性。

8.2 卷积模块

Padding “valid” 不补零，“same” 通常选择使 stride 为 1 时尺寸不变的 padding。

Stride 控制采样间隔并可下采样；过早使用大 stride 会丢失细节。

Dilation 在核元素间插入间隔，在不增加参数量的情况下扩大感受野。

分组与深度可分离卷积 减少通道连接和计算；深度卷积后接 1×1 pointwise 卷积。

池化 最大池化保留局部强响应，平均池化保留均值；二者均无可学习核。




图 8.1: 典型 CNN 的功能模块。实际网络会重复中间模块并增加残差连接。

8.3 经典架构

架构	主要年代/思想	关键贡献
LeNet-5	早期 CNN	卷积、池化、全连接组合，形成现代 CNN 基本模板。
AlexNet	2012	ReLU、Dropout、GPU 训练和大规模视觉数据推动深层 CNN 复兴。
VGG	2014	重复 3×3 小卷积，结构均匀但参数与计算量大。
GoogLeNet	2014	Inception 多分支与 1×1 降维，全局平均池化减少参数。
ResNet	2015	残差映射 $y = F(x) + x$ 改善深层网络的优化与信息传播。
EfficientNet	2019	联合缩放深度、宽度和分辨率，提高精度与算力的利用率。

残差块不要求 F 学到完整变换，而是学习相对输入的修正。维度不一致时，可用 stride 或 1×1 投影匹配捷径分支。残差连接缓解优化退化，不等于消除过拟合。

8.4 神经架构搜索

神经架构搜索 (neural architecture search, NAS) 包含三个要素：搜索空间、搜索策略和性能估计。早期 RL-NAS 用控制器生成架构并以验证性能为奖励，代价高。ENAS 让候选架构共享权重，降低性能评估开销。DARTS 将离散操作松弛为 softmax 混合，形成双层优化：

$$\min_{\alpha} \mathcal{L}_{\text{val}}(w^*(\alpha), \alpha), \quad w^*(\alpha) = \arg \min_w \mathcal{L}_{\text{train}}(w, \alpha). \tag{8.3}$$

连续松弛便于梯度优化，但权重共享会产生排序偏差，离散化后性能也可能变化。

EfficientNet 的复合缩放用系数 ϕ 同时控制

$$\text{depth} = \alpha^{\phi}, \quad \text{width} = \beta^{\phi}, \quad \text{resolution} = \gamma^{\phi},$$

并约束近似计算增长。它不属于搜索单个操作，而是系统分配额外算力。

第九章 图表示学习与图神经网络

本章导读

图把实体及关系表示为 $G = (V, E)$ 。图学习必须尊重节点编号的任意性，同时利用结构、属性和任务信号。本章从嵌入、消息传递到 Graph Transformer，再讨论表达力、过平滑与过挤压。

9.1 图数据与任务

图可以有向或无向、同构或异构、静态或动态。节点、边和整图都可带属性。主要任务包括：

- 节点级：节点分类、节点回归、异常检测；
- 边级：链接预测、关系分类；
- 图级：分子性质预测、图分类；
- 生成与检索：图生成、子图匹配和知识图谱推理。

图的节点顺序没有语义。图级模型应对节点置换不变，节点级模型应置换等变。

9.2 图嵌入

传统图嵌入先定义原图相似度，再学习编码器 z_v ，使解码器重建该相似度。例如内积解码器

$$p((u, v) \in E) = \sigma(z_u^T z_v).$$

随机游走方法把图上的游走序列当作“句子”，以共现关系学习节点向量。它们通常是传导式：新节点到来后需重新训练或额外处理。GNN 则用共享局部规则产生表示，更容易归纳到新图。

9.3 消息传递

一般消息传递神经网络（message passing neural network, MPNN）在第 ℓ 层计算

$$m_v^{(\ell)} = \text{AGG}^{(\ell)} \left\{ \psi^{(\ell)}(h_v^{(\ell-1)}, h_u^{(\ell-1)}, e_{uv}) : u \in \mathcal{N}(v) \right\}, \quad (9.1)$$

$$h_v^{(\ell)} = \phi^{(\ell)}(h_v^{(\ell-1)}, m_v^{(\ell)}). \quad (9.2)$$

AGG 必须对邻居顺序不变，如 sum、mean 或 max。

加入自环的 GCN 更新为

$$H^{(\ell+1)} = \sigma\left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(\ell)} W^{(\ell)}\right), \quad \tilde{A} = A + I. \quad (9.3)$$




图 9.1: GNN 通过邻居消息更新中心节点表示。

GraphSAGE 通过邻居采样和可学习聚合提高大图可扩展性。GAT 为邻边学习注意力权重

$$\alpha_{vu} = \text{softmax}_{u \in \mathcal{N}(v)} \left(\text{LeakyReLU}(a^T [Wh_v || Wh_u]) \right).$$

9.4 Graph Transformer 与基础模型

全局 self-attention 能直接连接远距离节点，但单靠内容注意力无法区分许多图结构。Graph Transformer 常加入最短路径距离、度、边类型、Laplacian 特征向量或随机游走统计作为结构编码。密集注意力仍为 $O(|V|^2)$ ，大图需稀疏化、分块或层次方法。

图基础模型尝试通过大规模预训练、提示和统一任务接口迁移到不同图。LLM 可以把文本属性转成语义特征、生成图查询或解释结果；图也可作为 LLM 的外部结构化记忆。二者结合时必须明确序列化方式、结构信息是否丢失，以及答案是否真正由图证据支持。

9.5 理论：表达、训练与泛化

9.5.1 表达力与 WL 检验

一阶消息传递 GNN 的区分能力通常不超过 1-WL 颜色细化。图同构网络（GIN）使用

$$h_v^{(\ell)} = \text{MLP}^{(\ell)} \left((1 + \epsilon^{(\ell)}) h_v^{(\ell-1)} + \sum_{u \in \mathcal{N}(v)} h_u^{(\ell-1)} \right), \quad (9.4)$$

在适当条件下达到 1-WL 级别表达力。更高阶 GNN 或位置编码可区分更多图，但成本更高。

9.5.2 过平滑与过挤压

层数加深时，反复邻域平均可能使节点表示趋同，称为过平滑（over-smoothing）。残差、归一化、跳连和解耦传播可缓解。过挤压（over-squashing）指指数增长的远程信息被压入固定维向量，常与图曲率和瓶颈有关；图重连、全局节点和注意力可缩短有效路径。

易错点

训练集和测试集节点位于同一张图时，消息传递可能接触测试节点的特征。这不一定是标签泄漏，但属于传导式设定；报告结果时必须说明是否允许使用测试图结构与无标签特征。

第十章 序列、注意力与 Transformer

本章导读

固定长度上下文向量限制了早期 Seq2Seq。注意力让解码器动态读取编码器状态，Transformer 进一步用 self-attention 取代循环，成为语言、视觉和多模态模型的共同骨架。

10.1 RNN 与 Seq2Seq

循环神经网络 (recurrent neural network, RNN) 递推

$$h_t = \phi(W_x x_t + W_h h_{t-1} + b).$$

反向传播通过时间展开 (backpropagation through time, BPTT)，长序列中的 Jacobian 连乘会造成梯度消失或爆炸。LSTM 和 GRU 通过门控缓解，但顺序依赖仍限制并行。

经典编码器-解码器把源序列压缩成固定上下文 c ，再按 $p(y_t | y_{<t}, c)$ 解码。固定向量对长序列形成信息瓶颈。

10.2 编码器-解码器注意力

注意力先计算解码状态 s_t 与编码状态 h_i 的匹配分数：

$$e_{ti} = \text{score}(s_{t-1}, h_i), \quad (10.1)$$

$$\alpha_{ti} = \frac{\exp(e_{ti})}{\sum_j \exp(e_{tj})}, \quad (10.2)$$

$$c_t = \sum_i \alpha_{ti} h_i. \quad (10.3)$$

Bahdanau attention 使用可学习加性网络，Luong attention 常用点积或双线性形式。 α 的热力图可辅助观察对齐，但注意力权重不必等同于因果解释。

10.3 缩放点积注意力

给定输入 $X \in \mathbb{R}^{n \times d_{\text{model}}}$,

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V.$$

缩放点积注意力为

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V. \quad (10.4)$$

缩放 $\sqrt{d_k}$ 防止维度大时点积方差过大，使 softmax 过饱和。掩码 M 对不可见位置加 $-\infty$ ；因果掩码确保位置 t 不能读取未来 token。

多头注意力（multi-head attention）为

$$\text{MHA}(X) = [\text{head}_1 \parallel \cdots \parallel \text{head}_H] W_O,$$

每个头有独立投影，可在不同子空间建模关系。




图 10.1: 缩放点积 self-attention 的数据流。

10.4 Transformer 架构

Transformer 编码器层由 self-attention、前馈网络、残差和 Layer Normalization 组成。位置前馈网络逐 token 共享：

$$\text{FFN}(x) = W_2 \phi(W_1 x + b_1) + b_2.$$

解码器增加因果 self-attention，并在 encoder-decoder 模型中加入 cross-attention。Pre-Norm 将归一化放在子层前，通常更利于深层训练；原始架构多用 Post-Norm。

正弦位置编码为

$$\text{PE}(p, 2i) = \sin(p/10000^{2i/d}), \quad (10.5)$$

$$\text{PE}(p, 2i + 1) = \cos(p/10000^{2i/d}). \quad (10.6)$$

学习式绝对位置、相对位置和旋转位置编码也很常见。核心要求是向不含顺序的 attention 提供位置关系。

10.5 复杂度与稀疏注意力

标准 attention 的分数矩阵为 $n \times n$ ，时间和显存主项是 $O(n^2 d)$ 与 $O(n^2)$ 。局部窗口、块稀疏、低秩近似和检索机制都在减少长序列成本，但会改变可直接交互的 token 范围。RNN 的顺序计算不易并行，Transformer 的训练并行性更好；不能只用渐近复杂度判断实际速度。

10.6 代表性应用

GPT decoder-only，采用因果语言建模，适合开放式生成。

BERT encoder-only, 以 masked language modeling 学习双向表示, 适合理解任务。

ViT 把图像切成 patch token, 并使用 Transformer 编码器处理 [16]。

CLIP 对比学习图像和文本编码, 使二者进入共享语义空间 [17]。

上述名称代表训练目标和接口的差异, 而不是互斥的能力边界。现代系统常组合编码器、解码器、检索器和视觉模块。

第三部分

生成式模型与基础模型

第十一章 生成模型：自回归、VAE、GAN 与扩散

本章导读

生成模型试图刻画数据分布并产生新样本。自回归模型提供显式似然，VAE 用变分下界训练潜变量模型，GAN 以对抗博弈匹配分布，扩散模型学习逐步逆转加噪过程。

11.1 分布建模与分类

生成模型可按似然是否显式计算粗分：

- 显式密度：自回归模型直接分解似然；VAE 优化似然下界；正规化流使用可逆变换；
- 隐式密度：GAN 通过采样器和判别器训练，不直接给出规范化似然；
- 基于分数或扩散：学习不同噪声尺度下的分数或去噪方向。




图 11.1: 本章四类生成模型的训练视角。

11.2 自回归模型

链式法则把联合分布分解为

$$p_{\theta}(x) = \prod_{i=1}^D p_{\theta}(x_i | x_{<i}). \quad (11.1)$$

训练最大化 teacher-forcing 条件下的对数似然，采样则逐元素进行。PixelRNN 用二维 RNN 保证像素只能依赖既往位置；PixelCNN 用掩码卷积并行计算训练条件，采样仍是顺序的。自回归模型有精确似然和稳定训练，但生成延迟随序列长度增长，顺序选择也构成归纳偏置。

11.3 自编码器与变分自编码器

普通自编码器优化重构

$$\min_{\phi, \theta} \sum_i \ell(x_i, g_{\theta}(f_{\phi}(x_i))),$$

但任意潜向量未必能解码成合理样本。变分自编码器 (variational autoencoder, VAE) 引入生成模型

$$p_{\theta}(x, z) = p(z)p_{\theta}(x | z)$$

和近似后验 $q_{\phi}(z | x)$ 。对数似然分解为

$$\begin{aligned} \log p_{\theta}(x) = & \underbrace{\mathbb{E}_{q_{\phi}(z|x)} [\log p_{\theta}(x | z)] - D_{\text{KL}}(q_{\phi}(z | x) \| p(z))}_{\text{ELBO}(x; \theta, \phi)} \\ & + D_{\text{KL}}(q_{\phi}(z | x) \| p_{\theta}(z | x)). \end{aligned} \quad (11.2)$$

后一项非负，因此最大化证据下界 (evidence lower bound, ELBO) 同时改善重构并让近似后验靠近先验。

常设

$$q_{\phi}(z | x) = \mathcal{N}(z; \mu_{\phi}(x), \text{diag}(\sigma_{\phi}^2(x))),$$

并用重参数化

$$\epsilon \sim \mathcal{N}(0, I), \quad z = \mu_{\phi}(x) + \sigma_{\phi}(x) \odot \epsilon \quad (11.3)$$

把随机性移到无参数噪声，使梯度可穿过采样操作。重构项的具体形式取决于 $p_{\theta}(x | z)$ ，不是所有图像都应机械使用像素 MSE。

易错点

ELBO 是 $\log p_{\theta}(x)$ 的下界，不是“重构损失加 KL”的随意组合。符号正负取决于是在最大化 ELBO 还是最小化负 ELBO。

11.4 生成对抗网络

生成对抗网络 (generative adversarial network, GAN) 包含生成器 G 和判别器 D ：

$$\min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}} \log D(x) + \mathbb{E}_{z \sim p(z)} \log(1 - D(G(z))). \quad (11.4)$$

给定生成器，最优判别器为

$$D^*(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_g(x)}.$$

理论博弈达到 $p_g = p_{\text{data}}$ ，但实际交替梯度会受到判别器饱和、模式崩溃和训练振荡影响。常用非饱和和生成器损失 $-\mathbb{E}_z \log D(G(z))$ 提供更强早期梯度。

条件 GAN (conditional GAN, CGAN) 让 $G(z, y)$ 与 $D(x, y)$ 都接收条件 y ，实现可控生成。谱归一化、Wasserstein 目标、梯度惩罚和判别器更新比率都可改善稳定性，但没有单一技巧适合所有数据。

11.5 扩散模型

去噪扩散概率模型 (denoising diffusion probabilistic model, DDPM) 定义前向马尔可夫链

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t} x_{t-1}, \beta_t I).$$

令 $\alpha_t = 1 - \beta_t$ 、 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ ，可直接采样任意时刻：

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I). \quad (11.5)$$

常见训练目标让网络预测噪声：

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2]. \quad (11.6)$$

生成时从高斯噪声开始，重复预测反向均值并逐步去噪。扩散训练稳定、覆盖模式较好，但多步采样昂贵；潜空间扩散、确定性采样和蒸馏可降低成本。

11.6 四类模型的权衡

表 11.1: 生成模型比较。

模型	似然	训练	采样	常见问题
自回归	精确	稳定、并行 teacher forcing	顺序、较慢	暴露偏差
VAE	下界	稳定	一次前向	过平滑、后验坍塌
GAN	隐式	博弈、不稳定	一次前向	模式崩溃、难评价
Diffusion	变分/分数视角	稳定	多步	推理成本高

第十二章 大语言模型基础与训练

本章导读

大语言模型（large language model, LLM）以 token 序列建模为核心，通过大规模预训练获得通用能力，再经指令、偏好和参数高效微调适应人类任务。本章区分训练阶段、目标函数与推理接口。

12.1 Tokenization 与表示

模型处理 token 而非天然的“词”。Byte-pair encoding（BPE）从基础符号开始，反复合并语料中最高频的相邻符号对，形成固定词表。子词方法在词表大小、序列长度和未知词之间折中；不同 tokenizer 会改变长度、成本和跨语言表现。

算法：BPE 训练

1. 将语料表示为初始字符或字节符号序列。
2. 统计相邻符号对的频数，选择最高频的一对。
3. 将该符号对合并为新 token，并更新所有序列。
4. 重复到达到词表大小或合并次数。

token id 经嵌入矩阵映射为向量，并与位置信息结合。输入嵌入与输出投影可以共享权重，但维度和实现必须匹配。

12.2 预训练目标与架构

因果语言建模 最大化 $\sum_t \log p_\theta(x_t | x_{<t})$ ，对应 decoder-only 模型。

遮盖语言建模 随机遮盖 token，预测其原值，能使用双向上下文，典型为 encoder-only。

序列到序列去噪 破坏输入片段并由 encoder-decoder 重建，适合条件生成。

训练流水线包括数据采集与治理、去重与过滤、tokenization、预训练、验证和后训练。数据质量、分布覆盖、污染与版权状态都影响最终系统；参数规模不是唯一决定因素。

12.3 监督微调与指令微调

监督微调（supervised fine-tuning, SFT）在任务输入输出对上继续最小化 token 级负对数似然。指令微调（instruction fine-tuning, IFT）显式加入任务指令，并在多任务数据上训练，使模型能通过自然语言接口迁移。训练时通常只对目标响应 token 计损失，是否对提示计损失必须明确。



图 12.1: LLM 的典型训练与部署闭环。并非所有模型都经历每一步。

SFT 能教会格式与任务行为，但示范数据只提供“应输出什么”，不直接表达多个可行回答之间的偏好。

12.4 RLHF 与偏好建模

基于人类反馈的强化学习（reinforcement learning from human feedback, RLHF）通常包括：

1. 收集同一提示下多个回答的人类排序；
2. 训练奖励模型 $r_\phi(x, y)$ ；
3. 在不偏离参考策略过远的约束下优化语言模型。

常用 Bradley–Terry 偏好模型为

$$p_\phi(y_w \succ y_l | x) = \sigma(r_\phi(x, y_w) - r_\phi(x, y_l)). \quad (12.1)$$

策略目标可概括为

$$\max_{\theta} \mathbb{E}_{y \sim \pi_\theta(\cdot | x)} [r_\phi(x, y)] - \beta D_{\text{KL}}(\pi_\theta(\cdot | x) \| \pi_{\text{ref}}(\cdot | x)). \quad (12.2)$$

PPO 是实现该约束优化的一种方法，但 RLHF 不等同于 PPO。

12.5 DPO

Direct Preference Optimization (DPO) 把一类带 KL 约束的偏好优化化成直接分类目标 [20]：

$$\begin{aligned} \mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x, y_w, y_l)} \log \sigma \Big(& \beta [\log \pi_\theta(y_w | x) - \log \pi_{\text{ref}}(y_w | x) \\ & - \log \pi_\theta(y_l | x) + \log \pi_{\text{ref}}(y_l | x)] \Big). \end{aligned} \quad (12.3)$$

DPO 省去显式奖励模型与在线采样，训练更简单；其效果仍取决于偏好数据、参考模型和分布覆盖。

12.6 上下文学习

上下文学习（in-context learning, ICL）在推理时把任务说明和示例放入上下文，不更新参数。零样本、单样本和少样本分别提供 0、1 或少量示例。示例顺序、标签词、格式和相似度都会影响输出；应在独立验证集选择提示，避免把测试题嵌入提示。

语言模型对序列 $x_{1:T}$ 的困惑度为

$$\text{PPL} = \exp \left(-\frac{1}{T} \sum_{t=1}^T \log p_{\theta}(x_t | x_{<t}) \right).$$

较低困惑度表示模型赋予文本更高概率，但不能替代任务正确率、事实性和安全性评价。

12.7 LoRA 参数高效微调

LoRA (low-rank adaptation) 冻结预训练权重 W_0 ，学习低秩增量

$$W' = W_0 + \frac{\alpha}{r} BA, \quad B \in \mathbb{R}^{d_{\text{out}} \times r}, \quad A \in \mathbb{R}^{r \times d_{\text{in}}}, \quad r \ll \min(d_{\text{in}}, d_{\text{out}}). \quad (12.4)$$

它减少可训练参数与优化器状态，适合保存多个任务适配器。低秩并不自动保证效果；目标模块、秩、缩放、数据量和是否合并权重都需验证。

第十三章 LLM 进阶：推理、检索与风险

本章导读

本章补齐课程大纲中的 LLM Advances：用 Chain-of-Thought 分配推理 token，用 RAG 接入可更新证据，并用全生命周期视角识别生成式 AI 的可靠性、安全和治理风险。

13.1 Chain-of-Thought

Chain-of-Thought (CoT) 提示在少样本示例中加入中间推理步骤，使模型在生成最终答案前显式分解问题 [22]。其作用可理解为在推理时分配更多顺序计算，并向模型示范合适的问题分解。零样本 CoT 用简短指令诱导分步作答，但对模型规模、任务和提示措辞敏感。

Self-consistency 从同一提示采样多条推理路径，再对最终答案聚合：

$$\hat{a} = \arg \max_a \sum_{m=1}^M \mathbf{1}(a^{(m)} = a).$$

它用额外推理成本降低单条路径的偶然错误。Tree of Thoughts (ToT) 把中间状态组织成搜索树，允许候选扩展、评价、回溯和前瞻 [27]。

易错点

模型生成的推理文本是输出行为，不是内部计算的忠实因果记录。长推理也可能把早期错误扩散到后续步骤。评价应以最终正确性、可验证证据和成本为主，而不是以文本长度为主。

13.2 检索增强生成

检索增强生成 (retrieval-augmented generation, RAG) 把参数记忆与外部非参数记忆结合 [23]。基本流水线为：

1. 文档解析、分块、元数据清洗和索引；
2. 根据查询做稀疏、稠密或混合检索；
3. 对候选文档重排、去重并选择上下文；
4. 将证据与问题交给生成器，并返回可核验引用。

稠密检索常用双编码器分数

$$s(q, d) = E_q(q)^T E_d(d). \quad (13.1)$$

RAG 的概率视角可写为

$$p(y | x) \approx \sum_{z \in \text{TopK}(x)} p_{\eta}(z | x) p_{\theta}(y | x, z), \quad (13.2)$$




图 13.1: RAG 把检索质量与生成质量拆成可分别诊断的模块。

其中 z 是检索文档, η 与 θ 分别是检索器和生成器参数。

RAG 的失败可分为检索失败、上下文选择失败、生成器忽略证据、错误引用和索引过期。因此需要分别评测 recall@k 、重排质量、上下文相关性、答案正确性、引用忠实度和端到端延迟。检索到文档不代表回答被文档支持。

13.3 能力边界与评价

LLM 可以完成生成、翻译、摘要、信息抽取、代码和多模态任务, 也能表现出 ICL 与复杂推理。但流畅度不等于事实性; 自回归目标只要求预测合理 token, 不保证陈述可验证。评价集还可能进入训练语料, 造成污染。可靠评测应包含:

- 明确任务分布、基线、评分规则与不确定性;
- 报告准确性、校准、鲁棒性、效率和公平性, 而非单一平均分;
- 对开放式任务使用多评审、盲评和可复核证据;
- 在部署分布上做红队、压力测试和持续监测。

13.4 生成式 AI 风险

NIST Generative AI Profile 将风险管理放在整个生命周期, 强调 Govern、Map、Measure、Manage 四类持续活动 [24]。课程复习可将主要风险归为:

可靠性与信息完整性 confabulation、错误引用、内容来源不清和自动化偏差;

公平与社会影响 有害偏差、同质化、排斥性结果和人机关系误判;

隐私与知识产权 训练数据泄露、成员推断、敏感信息复现和权利不清;

安全与滥用 提示注入、数据投毒、模型窃取、恶意内容和能力滥用;

系统与供应链 第三方模型、数据、插件和工具之间的责任与依赖风险;

资源影响 训练与推理的能耗、成本和集中化。

缓解措施应与风险对应, 例如来源标注不能修复检索召回, 内容过滤不能修复权限越界。高风险场景需要最小权限、人工复核、日志、回滚、事件响应和独立审计。

第十四章 LLM Agent：规划、记忆与工具

本章导读

Agent 把语言模型放入“观察、决策、行动、反馈”的闭环。能力不只来自模型参数，还来自状态管理、计划、工具协议、记忆、权限边界和失败恢复。

14.1 Agent 的形式化视角

可将环境写成部分可观测决策过程。时刻 t ，Agent 根据历史 $h_t = (o_1, a_1, \dots, o_t)$ 选择动作

$$a_t \sim \pi_\theta(a \mid h_t),$$

环境转移并返回新观察和奖励。语言模型可充当策略或策略的一部分，但完整系统还包括：

- 任务目标、系统约束和停止条件；
- 工作记忆、长期记忆与状态压缩；
- 规划器、执行器、验证器和恢复策略；
- 工具描述、参数 schema、鉴权、超时与结果解析；
- 日志、预算、人工批准和安全策略。




图 14.1: Agent 的闭环；每次外部动作都应产生结构化观察。

14.2 ReAct

ReAct 在同一轨迹中交替生成推理、动作和观察，使推理根据外部证据更新，动作也受当前计划约束 [25]。

算法：ReAct 风格执行

1. 读取目标、当前状态、预算和允许的工具。
2. 形成下一步理由或子目标，但不把未验证假设当作事实。
3. 选择工具与结构化参数；在高影响动作前检查权限或请求批准。
4. 执行并把返回值解析为观察，记录错误、来源和时间。

5. 更新状态；若达到验收条件则停止，否则继续或采用恢复策略。

ReAct 的关键不是展示冗长思维，而是把“为什么行动、做了什么、环境返回什么”分开，从而支持调试与证据追踪。

14.3 规划与搜索

计划可分为一次性分解、滚动重规划和显式搜索。简单任务用线性清单即可；长任务需要在新观察后重规划。ToT 把候选思路当作搜索状态；其他系统也可用 beam search、Monte Carlo tree search 或外部约束求解器。规划器必须有可检验的终止条件，否则容易形成循环或不断扩大范围。

14.4 工具使用

工具调用应使用机器可验证 schema，而不是依赖自然语言猜测。Toolformer 展示了模型可通过自监督方式学习何时调用 API、传什么参数、如何使用结果 [26]。工程系统还需处理：

- 参数验证、幂等性、重试、超时与速率限制；
- 凭据隔离、最小权限和敏感字段脱敏；
- 工具结果可能不可信，网页或文档中的提示可能造成间接提示注入；
- 写操作与不可逆操作必须有更严格的审批和审计。

14.5 记忆

工作记忆保存当前轨迹，长期记忆保存跨会话事实或经验。长期记忆写入前要做去重、来源记录、权限检查和过期策略；检索时要区分用户事实、模型推断和外部证据。摘要能节省上下文，但会丢失细节，应保留指向原始记录的引用。

14.6 评测与安全

Agent 的成功率需同时考虑任务完成、步骤成本、工具错误、恢复能力和安全违规。常用测试包括正常路径、工具超时、空结果、冲突证据、权限不足、提示注入、循环计划和中途取消。

易错点

把自主循环次数设为很大并不能提高可靠性。每个循环都可能扩大错误；必须设置时间、token、费用和动作预算，并在预算耗尽时返回可恢复状态。

第十五章 元学习与少样本适应

本章导读

元学习 (meta-learning) 不是在一个数据集上调超参数, 而是在任务分布上学习适应规则。本章用 support/query episode 统一度量式和优化式方法, 并连接迁移学习与 ICL。

15.1 任务分布与 episodic training

设任务 $\tau \sim p(\tau)$, 每个任务含支持集 S_τ 和查询集 Q_τ 。元训练目标为

$$\min_{\theta} \mathbb{E}_{\tau \sim p(\tau)} [\mathcal{L}_{Q_\tau}(\text{Adapt}(\theta, S_\tau))]. \quad (15.1)$$

支持集模拟新任务可用的少量数据, 查询集评价适应后的泛化。 N -way K -shot 表示每个 episode 从 N 类各取 K 个支持样本。




图 15.1: 元学习 episode 的数据角色。Support 与 Query 不可混用。

15.2 度量式元学习

Matching Networks 对支持样本作注意力加权的近邻分类 [28]:

$$p(y = c \mid x, S) = \sum_{(x_i, y_i) \in S} a(x, x_i) \mathbf{1}(y_i = c), \quad (15.2)$$

其中 a 由学习到的嵌入相似度归一化得到。

Prototypical Networks 为每类计算原型

$$c_k = \frac{1}{|S_k|} \sum_{(x_i, y_i) \in S_k} f_{\theta}(x_i), \quad (15.3)$$

并按距离分类

$$p_{\theta}(y = k \mid x) = \frac{\exp[-d(f_{\theta}(x), c_k)]}{\sum_j \exp[-d(f_{\theta}(x), c_j)]}. \quad (15.4)$$

其简单归纳偏置要求同类在嵌入空间聚成单峰。类内多模态时，一个均值原型可能不足。

15.3 MAML

Model-Agnostic Meta-Learning (MAML) 学习一个易于少步适应的初始化 [30]。单步内循环为

$$\theta'_\tau = \theta - \alpha \nabla_\theta \mathcal{L}_{S_\tau}(\theta),$$

外循环为

$$\min_{\theta} \sum_{\tau} \mathcal{L}_{Q_\tau}(\theta'_\tau). \quad (15.5)$$

对 θ 求外层梯度需穿过内层更新，因此包含二阶项。First-Order MAML 忽略该项以降低成本。

Reptile 从初始化出发在任务内训练若干步得到 $\tilde{\theta}_\tau$ ，再更新

$$\theta \leftarrow \theta + \epsilon(\tilde{\theta}_\tau - \theta). \quad (15.6)$$

它只用一阶信息，却鼓励不同任务内批次的梯度方向具有可迁移结构 [31]。

15.4 与迁移学习和 ICL 的关系

表 15.1: 三类快速适应方法。

方法	训练单位	测试时适应	主要学习对象
迁移学习	样本或单一数据集	微调参数	通用表示
元学习	任务 episode	少步更新或度量	适应规则或初始化
ICL	序列上下文	不更新参数	由预训练模型在上下文中推断

三者可以组合，例如用元学习训练可快速微调的表示，或用检索选择 ICL 示例。公平比较必须匹配预训练数据、适应样本数、计算预算与是否允许更新参数。

易错点

若元训练与元测试共享类别或泄漏相同对象，少样本结果会被高估。任务划分必须先按类、用户、环境或时间等真正需要泛化的单位进行，再在任务内部划分 support/query。

附录 A ADMM 与分布式优化

本章导读

本附录浓缩 Boyd 等人的 ADMM 专论 [3]。交替方向乘子法 (alternating direction method of multipliers, ADMM) 把可分解目标、增广拉格朗日和交替最小化结合, 尤其适合带结构约束、稀疏正则或分布式数据的问题。

A.1 从对偶上升到增广拉格朗日

考虑

$$\min_x f(x) \quad \text{s.t.} \quad Ax = b. \quad (\text{A.1})$$

拉格朗日函数为 $L(x, y) = f(x) + y^\top (Ax - b)$ 。对偶上升交替最小化 x 并更新 $y^{k+1} = y^k + \rho(Ax^{k+1} - b)$, 但其收敛依赖较强条件。

增广拉格朗日加入二次罚项

$$L_\rho(x, y) = f(x) + y^\top (Ax - b) + \frac{\rho}{2} \|Ax - b\|^2. \quad (\text{A.2})$$

罚项改善数值性质, 又不改变可行最优解; 标准乘子法的联合 x 更新却可能破坏问题的可分结构。

A.2 标准 ADMM

对二块问题

$$\begin{aligned} \min_{x, z} \quad & f(x) + g(z) \\ \text{s.t.} \quad & Ax + Bz = c, \end{aligned} \quad (\text{A.3})$$

增广拉格朗日为

$$L_\rho(x, z, y) = f(x) + g(z) + y^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|^2.$$

令缩放对偶变量 $u = y/\rho$, 标准更新为

$$x^{k+1} = \arg \min_x \left[f(x) + \frac{\rho}{2} \|Ax + Bz^k - c + u^k\|^2 \right], \quad (\text{A.4})$$

$$z^{k+1} = \arg \min_z \left[g(z) + \frac{\rho}{2} \|Ax^{k+1} + Bz - c + u^k\|^2 \right], \quad (\text{A.5})$$

$$u^{k+1} = u^k + Ax^{k+1} + Bz^{k+1} - c. \quad (\text{A.6})$$

它按顺序使用最新 x^{k+1} , 因此不是两个子问题完全并行的 Jacobi 更新。

定理 A.1: 标准凸条件下的 ADMM 收敛

若 f 与 g 是闭、真、凸函数，且未增广拉格朗日存在鞍点，则标准二块 ADMM 在精确子问题更新下使原始残差趋于零、目标值趋于最优值、对偶变量趋于某个对偶最优解。该结论不自动覆盖非凸目标、多块直接循环更新或无限精度误差。

A.3 残差与停止准则

原始残差和一般形式的对偶残差为

$$r^k = Ax^k + Bz^k - c, \quad s^k = \rho A^\top B(z^k - z^{k-1}). \quad (\text{A.7})$$

当约束为 $x - z = 0$ 时，忽略符号后 $\|s^k\| = \rho \|z^k - z^{k-1}\|$ 。常用停止条件为

$$\|r^k\| \leq \epsilon_{\text{pri}}, \quad \|s^k\| \leq \epsilon_{\text{dual}},$$

其中

$$\epsilon_{\text{pri}} = \sqrt{p} \epsilon_{\text{abs}} + \epsilon_{\text{rel}} \max\{\|Ax^k\|, \|Bz^k\|, \|c\|\}, \quad (\text{A.8})$$

$$\epsilon_{\text{dual}} = \sqrt{n} \epsilon_{\text{abs}} + \epsilon_{\text{rel}} \|A^\top y^k\|. \quad (\text{A.9})$$

p 是约束维度， n 是 x 维度。只观察目标值不足以判断约束是否满足。

A.4 近端形式与常见模式

约束 $x = z$ 时， x 更新和 z 更新常成为近端算子。若

$$\min_x f(x) + g(Cx),$$

引入 $z = Cx$ 即得 ADMM 形式。通过变量分裂，可把光滑数据拟合与非光滑正则分别处理。

二次子问题

$$\min_x \frac{1}{2} x^\top P x + q^\top x + \frac{\rho}{2} \|Ax - v\|^2$$

满足线性系统

$$(P + \rho A^\top A)x = \rho A^\top v - q.$$

当矩阵固定时，应缓存 Cholesky 或其他分解，而不是每轮重新求逆。

A.5 Lasso 示例

对

$$\min_x \frac{1}{2} \|Xx - y\|^2 + \lambda \|x\|_1,$$

令 $x = z$ 。ADMM 更新为

$$(X^T X + \rho I)x^{k+1} = X^T y + \rho(z^k - u^k), \quad (\text{A.10})$$

$$z^{k+1} = S_{\lambda/\rho}(x^{k+1} + u^k), \quad (\text{A.11})$$

$$u^{k+1} = u^k + x^{k+1} - z^{k+1}. \quad (\text{A.12})$$

这把一次可缓存的线性求解与廉价软阈值分开。 ρ 改变算法路径和残差平衡，但不改变原问题最优解。

A.6 共识与共享

共识优化写作

$$\min_{\{x_i\}, z} \sum_{i=1}^N f_i(x_i) \quad \text{s.t.} \quad x_i = z.$$

每个工作节点并行更新本地 x_i ，中心或通信协议聚合得到 z ，再更新对偶变量。它适合按样本、设备或机构分解数据。共享问题则形如

$$\min_{\{x_i\}} \sum_i f_i(x_i) + g\left(\sum_i x_i\right),$$

耦合通过总和发生，可经辅助变量转为可分更新。

分布式实现的瓶颈常是通信而非算术。必须说明同步/异步策略、丢包和失败处理、数据隐私、局部求解精度与停止条件。

A.7 变体与实践

过松弛 在 z 更新前用 $\alpha Ax^{k+1} + (1 - \alpha)(c - Bz^k)$ 替换 Ax^{k+1} ，常取 $1 < \alpha < 2$ 加速，但需验证。

自适应 ρ 若 $\|r\|$ 远大于 $\|s\|$ ，增大 ρ ；反之减小。改变 ρ 时要相应缩放 $u = y/\rho$ ，保持未缩放对偶变量一致。

不精确更新 大子问题可迭代近似求解；误差需受控，不能每轮任意截断。

多块与非凸 直接把二块公式扩展到三块以上或非凸问题，不再自动继承标准收敛保证。

易错点

ADMM 很适合结构化凸问题，但并非所有场景都比专用一阶法或二阶法快。比较时应同时计入线性系统分解、通信、内存和达到给定精度的总时间。

附录 B 总复习：算法选型与公式速查

B.1 按问题结构选方法

问题信号	优先考虑	先检查
小样本、局部边界	k-NN、核 SVM	特征尺度、距离或核、查询成本
表格数据、非线性交互	树、随机森林、梯度提升	泄漏、类别不平衡、概率校准
连续目标与可解释系数	线性/Ridge/Lasso	残差、共线性、尺度、正则选择
无标签分组	K-means、DBSCAN、GMM、谱聚类	簇形状、密度、距离尺度、稳定性
低维表示	PCA、AE、对比学习	线性假设、重构与下游指标
网格数据	CNN、ViT	分辨率、数据量、局部性和算力
关系数据	GNN、Graph Transformer	图构造、传导设置、长程依赖
开放式生成	自回归、VAE、GAN、Diffusion	似然、质量、多样性、采样成本
知识需更新或引用	RAG	索引、召回、忠实引用、权限
多步外部操作	Agent	工具 schema、预算、审批、恢复
少样本新任务	迁移、Meta-Learning、ICL	任务划分、适应预算、污染

B.2 优化器速查

方法	核心更新	适用与风险
GD	$x \leftarrow x - \eta \nabla f(x)$	确定性基线；全梯度在大数据上昂贵。
Momentum	$v \leftarrow \beta v + g, x \leftarrow x - \eta v$	加速一致方向，可能在高学习率下振荡。
SGD	用 mini-batch 梯度 g_t	可扩展且有噪声；需调学习率与 batch。
AdaGrad	累积 g_t^2 作逐坐标缩放	稀疏特征友好；后期步长可能过小。
RMSProp	指数平均 g_t^2	避免无限累积；依赖衰减系数。
AdamW	偏差修正矩估计加解耦衰减	常用深度学习默认；仍需调学习率和衰减。
ISTA/FISTA	梯度步加 prox	光滑加非光滑凸目标；FISTA 函数值收敛更快。

方法	核心更新	适用与风险
ADMM	分裂变量、交替最小化、对偶更新	结构约束和分布式问题；每步子问题成本关键。

B.3 核心公式索引

主题	定位
经验风险	式 (1.1)
SVM 原问题与对偶	式 (2.2)；定理 2.1
Ridge / Lasso	式 (3.5)；式 (3.6)
K-means / PCA	式 (5.1)；定理 5.1
AdamW / 近端梯度	式 (6.7)；式 (6.10)
反向传播	式 (7.5)
卷积尺寸	式 (8.2)
GNN 消息传递	式 (9.2)
缩放点积注意力	式 (10.4)
VAE ELBO / GAN / Diffusion	式 (11.2)；式 (11.4)；式 (11.6)
RLHF / DPO / LoRA	式 (12.2)；式 (12.3)；式 (12.4)
RAG / MAML	式 (13.2)；式 (15.5)
ADMM 更新与残差	式 (A.4)；式 (A.5)；式 (A.6)；式 (A.7)

B.4 考前自检

对任一算法，应能回答：

- 1. 输入、输出和数据假设是什么？
- 2. 优化的目标函数是什么，哪些量是参数、超参数或随机变量？
- 3. 一步更新如何计算，时间与空间瓶颈在哪里？
- 4. 该方法的归纳偏置和失败模式是什么？
- 5. 验证集、测试集和线上反馈各承担什么角色？
- 6. 结论依赖哪些理论条件，现实实现是否满足？

附录 C PDF 来源与章节覆盖

下表以主要知识点而非逐页编号建立覆盖关系。封面、重复 Roadmap、致谢和课堂互动页不单列。
课程 Slide 统一记为 [1]，补充讲义记为 [2]。

源文件	对应章节	已整合主题
MI-L1-Introduction.pdf	第 1 章	课程概览、AI 历史、基本学习概念、学习范式、数据划分与总结。
MI-L2-Classifier1.pdf	第 2、4 章	分类器动机、k-NN、距离与高维问题、SVM 原始/对偶/核、多分类、决策树；集成预告并入第 4 章。
MI-L3-Regression.pdf	第 3 章	线性回归、逻辑回归、过拟合、Ridge、Lasso、泛化误差和正则化。
MI-L4-Ensemble.pdf	第 4 章	偏差方差、Voting、Bagging、Random Forest、AdaBoost、Gradient Boosting、Stacking。
MI-L5-Unsupervised.pdf	第 5 章	K-means、DBSCAN、谱聚类、PCA、LLE、t-SNE、GMM、KDE、SimCLR 与对比学习。
MI-L6-Optimization.pdf	第 6 章、附录 A	梯度下降、损失地形、Momentum、Nesterov、SGD、学习率、AdaGrad、RMSProp、AdamW、近端映射、ISTA 与 FISTA。
L7-UnsupervisedLearning.pdf	第 5、12 章	聚类复习、SimCLR、MoCo、遮盖学习、Masked VAE、Noise2Noise、Noise2Void、R2R、低频偏置、Deep Image Prior、Gaussian-process prior、PCA、字典学习、AE、LoRA。
MI-L8-CNN.pdf	第 7、8 章	MLP 回顾、卷积与互相关、1D/2D/3D 卷积、stride、padding、pooling、FC、LeNet、AlexNet、VGG、GoogLeNet、ResNet、NAS、ENAS、DARTS、EfficientNet。
MI-L9-GNN.pdf	第 9、10 章	图任务、图嵌入、GNN 消息传递、GCN/GAT、Graph Transformer、图基础模型与 LLM、WL/GIN 表达力、过平滑、过挤压和泛化。
MI-L10-Transformer.pdf	第 10 章	Seq2Seq、RNN/BPTT、Bahdanau/Luong attention、self-attention、QKV、掩码、多头、位置编码、完整 Transformer、局部/稀疏 attention、GPT、BERT、ViT、CLIP。
MI-L11-Generative.pdf	第 11 章	判别与生成、PixelRNN/CNN、AE、VAE 推导、GAN/CGAN 与训练、DDPM 前向和反向过程。
MI-L12-LLM-Basics.pdf	第 12、13 章	LLM 能力、架构、BPE、预训练、MLM/causal LM、SFT/IFT、RLHF、ICL、zero/one/few-shot、提示与困惑度。
非常好的优化指南论文.pdf	附录 A	对偶分解、增广拉格朗日、ADMM、收敛、残差、近端模式、约束优化、稀疏问题、共识与共享优化、分布式实现和变体。

中英术语表

中文	English	缩写
经验风险最小化	empirical risk minimization	ERM
支持向量机	support vector machine	SVM
主成分分析	principal component analysis	PCA
高斯混合模型	Gaussian mixture model	GMM
核密度估计	kernel density estimation	KDE
随机梯度下降	stochastic gradient descent	SGD
多层感知机	multilayer perceptron	MLP
卷积神经网络	convolutional neural network	CNN
图神经网络	graph neural network	GNN
消息传递神经网络	message passing neural network	MPNN
变分自编码器	variational autoencoder	VAE
生成对抗网络	generative adversarial network	GAN
大语言模型	large language model	LLM
监督微调	supervised fine-tuning	SFT
上下文学习	in-context learning	ICL
基于人类反馈的强化学习	reinforcement learning from human feedback	RLHF
直接偏好优化	direct preference optimization	DPO
检索增强生成	retrieval-augmented generation	RAG
思维链	chain-of-thought	CoT
低秩适应	low-rank adaptation	LoRA
交替方向乘子法	alternating direction method of multipliers	ADMM

参考文献

- [1] Yaqing Wang. *Machine Intelligence, Lectures 1–6 and 8–12*. BIMS course slides, Fall 2025.
- [2] Pang Tongyao. *Deep Learning Lecture 7: Unsupervised Learning*. YMSC course slides, 2025.
- [3] Stephen Boyd, Neal Parikh, Eric Chu, Borja Peleato, and Jonathan Eckstein. Distributed optimization and statistical learning via the alternating direction method of multipliers. *Foundations and Trends in Machine Learning*, 3(1):1–122, 2011. <https://doi.org/10.1561/22000000016>.
- [4] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323:533–536, 1986. <https://doi.org/10.1038/323533a0>.
- [5] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20:273–297, 1995.
- [6] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [7] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232, 2001.
- [8] Arthur P. Dempster, Nan M. Laird, and Donald B. Rubin. Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society, Series B*, 39(1):1–38, 1977.
- [9] Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey Hinton. A simple framework for contrastive learning of visual representations. In *Proceedings of ICML*, 2020.
- [10] Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In *Proceedings of CVPR*, 2020.
- [11] Diederik P. Kingma and Max Welling. Auto-encoding variational Bayes. In *Proceedings of ICLR*, 2014.
- [12] Ian Goodfellow et al. Generative adversarial nets. In *Advances in Neural Information Processing Systems* 27, 2014.
- [13] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems* 33, 2020.
- [14] Ashish Vaswani et al. Attention is all you need. In *Advances in Neural Information Processing Systems* 30, 2017.
- [15] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, 2019.

- [16] Alexey Dosovitskiy et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *Proceedings of ICLR*, 2021.
- [17] Alec Radford et al. Learning transferable visual models from natural language supervision. In *Proceedings of ICML*, 2021.
- [18] Tom B. Brown et al. Language models are few-shot learners. In *Advances in Neural Information Processing Systems 33*, 2020.
- [19] Long Ouyang et al. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems 35*, 2022.
- [20] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. In *Advances in Neural Information Processing Systems 36*, 2023.
- [21] Edward J. Hu et al. LoRA: Low-rank adaptation of large language models. In *Proceedings of ICLR*, 2022.
- [22] Jason Wei et al. Chain-of-thought prompting elicits reasoning in large language models. In *Advances in Neural Information Processing Systems 35*, 2022.
- [23] Patrick Lewis et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems 33*, 2020.
- [24] Chloe Autio et al. Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile. NIST AI 600-1, 2024; updated 2026. <https://doi.org/10.6028/NIST.AI.600-1>.
- [25] Shunyu Yao et al. ReAct: Synergizing reasoning and acting in language models. In *Proceedings of ICLR*, 2023.
- [26] Timo Schick et al. Toolformer: Language models can teach themselves to use tools. In *Advances in Neural Information Processing Systems 36*, 2023.
- [27] Shunyu Yao et al. Tree of thoughts: Deliberate problem solving with large language models. In *Advances in Neural Information Processing Systems 36*, 2023.
- [28] Oriol Vinyals, Charles Blundell, Timothy Lillicrap, Koray Kavukcuoglu, and Daan Wierstra. Matching networks for one shot learning. In *Advances in Neural Information Processing Systems 29*, 2016.
- [29] Jake Snell, Kevin Swersky, and Richard Zemel. Prototypical networks for few-shot learning. In *Advances in Neural Information Processing Systems 30*, 2017.
- [30] Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *Proceedings of ICML*, 2017.
- [31] Alex Nichol, Joshua Achiam, and John Schulman. On first-order meta-learning algorithms. *arXiv:1803.02999*, 2018.